


LAPORAN PROJECT MACHINE LEARNING
MOBILE PRICE CLASSIFICATION



Dosen Pengampu: Lutfiah Maharani Siniwi, S.Stat., M.Stat.

Disusun oleh:

Sherly Steffiyani Askarilia	(K1D024042)
Wahyu Putra Ramadhan	(K1D024072)
Nata Naila Zakya Ramadani	(K1D024073)
Rohmatunnissa Agnar Azarine	(K1D024074)

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
PURWOKERTO

2026

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga laporan *project* akhir mata kuliah *Machine Learning* ini dapat diselesaikan dengan baik dan tepat waktu.

Laporan ini disusun sebagai bentuk pertanggungjawaban atas pelaksanaan *project* akhir yang menggantikan Ujian Akhir Semester (UAS) pada mata kuliah *Machine Learning* Kelas B. Dalam *project* ini, kami menerapkan keseluruhan alur kerja *machine learning* mulai dari pendefinisian masalah, eksplorasi data, prapemrosesan, pemodelan, hingga evaluasi dan interpretasi hasil, dengan mengambil studi kasus klasifikasi segmen harga perangkat *mobile*.

Kami menyadari bahwa penyelesaian *project* ini tidak terlepas dari dukungan dan bimbingan berbagai pihak. Oleh karena itu, kami menyampaikan terima kasih kepada:

1. Ibu Lutfiah Maharani Siniwi, S.Stat., M.Stat. selaku dosen pengampu mata kuliah *Machine Learning* yang telah membimbing dan memberikan arahan selama proses pengerjaan *project* ini.
2. Seluruh anggota kelompok yang telah berkontribusi secara aktif dan bekerja sama dengan penuh tanggung jawab dalam setiap tahapan pengerjaan.
3. Berbagai pihak yang tidak dapat disebutkan satu per satu, yang telah memberikan dukungan baik secara langsung maupun tidak langsung.

Kami menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang bersifat membangun sangat kami harapkan demi perbaikan di masa mendatang. Semoga laporan ini dapat memberikan manfaat dan menjadi referensi yang berguna bagi pembaca.

Purwokerto, Juni 2026

Tim Penyusun

BAB I

PENDAHULUAN

1.1 Latar Belakang

Industri perangkat *mobile* merupakan salah satu sektor teknologi yang berkembang paling pesat dalam beberapa dekade terakhir. Setiap tahunnya, ratusan model ponsel baru diluncurkan oleh berbagai produsen dengan beragam spesifikasi teknis dan segmen harga yang ditawarkan kepada konsumen. Di tengah persaingan pasar yang semakin ketat, penetapan harga menjadi salah satu keputusan strategis yang sangat krusial, baik bagi produsen dalam memposisikan produknya, maupun bagi konsumen dalam memilih perangkat yang sesuai dengan kebutuhan dan anggaran mereka.

Selama ini, penentuan segmen harga sebuah ponsel umumnya dilakukan secara manual berdasarkan pengalaman tim pemasaran atau perbandingan terhadap produk kompetitor. Pendekatan ini memiliki keterbatasan karena bersifat subjektif dan tidak selalu mencerminkan hubungan objektif antara spesifikasi teknis dengan nilai harga yang wajar di pasar. Terlebih, dengan semakin banyaknya variabel teknis yang terlibat, mulai dari kapasitas RAM, daya baterai, resolusi kamera, hingga fitur konektivitas kompleksitas dalam pengambilan keputusan harga semakin meningkat dan sulit ditangani secara intuitif.

Machine learning menawarkan pendekatan yang lebih sistematis dan berbasis data untuk menjawab permasalahan tersebut. Dengan memanfaatkan data spesifikasi teknis dari ribuan perangkat *mobile*, sebuah model klasifikasi dapat dilatih untuk mempelajari pola hubungan antara fitur-fitur teknis dengan segmen harga yang terbentuk di pasar. Namun demikian, tidak semua fitur teknis memberikan kontribusi yang setara terhadap pembentukan harga. Terdapat kemungkinan bahwa sebagian besar kemampuan prediktif model justru hanya bergantung pada segelintir fitur dominan, sementara fitur lainnya bersifat redundan dan tidak memberikan informasi tambahan yang signifikan.

Berdasarkan kondisi tersebut, *project* ini tidak hanya bertujuan membangun model klasifikasi segmen harga perangkat *mobile*, tetapi juga mengkaji secara lebih mendalam mengenai kontribusi masing-masing fitur teknis dan dampaknya terhadap kinerja model ketika *subset* fitur

yang berbeda digunakan. Pendekatan ini diharapkan dapat menghasilkan model yang tidak hanya akurat, tetapi juga efisien dan mudah diinterpretasikan.

1.2 Rumusan Masalah

Penetapan segmen harga perangkat *mobile* di pasar melibatkan banyak variabel teknis yang saling berkaitan, namun tidak semua variabel tersebut memberikan kontribusi yang setara terhadap pembentukan harga. Berdasarkan kondisi tersebut, rumusan masalah dalam *project* ini adalah:

1. Apakah terdapat ketimpangan kontribusi antar fitur teknis dalam menentukan segmen harga perangkat *mobile*, dan fitur mana yang secara konsisten paling dominan lintas algoritma yang berbeda?
2. Sejauh mana model *machine learning* mampu mempertahankan akurasi klasifikasi segmen harga ketika dibangun hanya menggunakan *subset* fitur terpilih dibandingkan menggunakan seluruh fitur yang tersedia?
3. Algoritma mana yang paling optimal dalam menangani pola klasifikasi multikelas pada data spesifikasi perangkat *mobile* dengan distribusi kelas yang seimbang?

1.3 Tujuan

Berdasarkan rumusan masalah di atas, tujuan dari *project* ini adalah:

1. Mengidentifikasi fitur-fitur teknis yang paling dominan dan konsisten berpengaruh terhadap penentuan segmen harga perangkat *mobile* berdasarkan analisis *feature importance* lintas algoritma.
2. Membandingkan kinerja model *machine learning* yang dibangun menggunakan seluruh fitur dengan model yang hanya menggunakan *subset* fitur terpilih, untuk mengevaluasi efisiensi dan efektivitas seleksi fitur.
3. Membangun dan membandingkan beberapa algoritma klasifikasi untuk menemukan model yang paling optimal dalam memprediksi segmen harga perangkat *mobile*.

1.4 Manfaat

Hasil dari *project* ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Bagi produsen perangkat *mobile*, model ini dapat digunakan sebagai alat bantu dalam memposisikan produk baru ke segmen harga yang tepat sebelum diluncurkan ke pasar, cukup berdasarkan spesifikasi teknis yang telah ditentukan.
2. Bagi konsumen, pemahaman tentang fitur-fitur yang paling memengaruhi segmen harga dapat membantu dalam pengambilan keputusan pembelian yang lebih rasional dan terinformasi.
3. Bagi akademisi dan praktisi data, hasil analisis *feature importance* dan perbandingan model dalam *project* ini dapat menjadi referensi dalam merancang *pipeline machine learning* yang lebih efisien pada data spesifikasi teknis serupa.

1.5 Jenis Masalah

Permasalahan dalam *project* ini dikategorikan sebagai klasifikasi multikelas (*multi-class classification*). Hal ini dikarenakan variabel target yang digunakan, yaitu *price_range*, memiliki empat kelas diskrit (0, 1, 2, 3) yang merepresentasikan segmen harga dari rendah hingga sangat tinggi. Karena *output* yang diharapkan berupa label kategori dan bukan nilai kontinu, maka pendekatan regresi tidak tepat digunakan dalam konteks ini.

Pemilihan jenis masalah klasifikasi juga didukung oleh karakteristik distribusi target yang seimbang, di mana masing-masing kelas memiliki jumlah observasi yang sama, yaitu 500 data per kelas. Kondisi ini menjadikan dataset ini ideal untuk melatih dan mengevaluasi model klasifikasi tanpa perlu khawatir terhadap bias akibat ketidakseimbangan kelas.

1.6 Batasan Masalah

Agar pembahasan dalam *project* ini tetap terarah dan terfokus, ditetapkan beberapa batasan sebagai berikut:

1. Dataset yang digunakan terbatas pada data spesifikasi teknis perangkat *mobile* yang tersedia pada dataset *Mobile Price Classification* dari Kaggle, tanpa penambahan data dari sumber eksternal lain.
2. Variabel target yang digunakan hanya *price_range* dengan empat kelas, dan tidak mencakup prediksi harga dalam nilai nominal rupiah atau mata uang lainnya.
3. Algoritma yang digunakan dibatasi pada empat algoritma klasifikasi, yaitu *Logistic Regression*, *Random Forest*, dan *XGBoost*.

4. Eksperimen seleksi fitur dilakukan menggunakan pendekatan berbasis *feature importance* dari model pohon keputusan, tanpa metode *wrapper* seperti *Recursive Feature Elimination* (RFE).

BAB II

TINJAUAN DATASET

2.1 Deskripsi Dataset

Dataset yang digunakan dalam project ini adalah *Mobile Price Classification* yang bersumber dari platform Kaggle dan dapat diakses secara publik melalui tautan berikut:

<https://www.kaggle.com/datasets/iabhishekofficial/mobile-price-classification/data?select=train.csv>

Dataset ini dikumpulkan untuk mensimulasikan permasalahan klasifikasi harga perangkat mobile berdasarkan spesifikasi teknisnya. Data terdiri dari 2.000 observasi (baris) dan 21 variabel (kolom), di mana 20 kolom merupakan variabel fitur dan 1 kolom merupakan variabel target.

Karakteristik Umum Data:

Karakteristik	Keterangan
Jumlah Observasi	2.000 baris
Jumlah Variabel	21 kolom (20 fitur + 1 target)
<i>Missing Value</i>	Tidak ada (0 pada seluruh kolom)
Tipe Data	<i>Integer</i> (int64) dan <i>Float</i> (float64)
Distribusi Kelas Target	Seimbang dengan masing-masing kelas 500 data
Sumber	Kaggle (iabhishekofficial)

2.2 Data Dictionary (Deskripsi Variabel)

No	Nama Variabel	Tipe Data	Deskripsi
1	battery_power	int64	Kapasitas baterai dalam mAh (501–1998)
2	blue	int64	Dukungan Bluetooth (0 = Tidak, 1 = Ya)
3	clock_speed	float64	Kecepatan prosesor dalam GHz
4	dual_sim	int64	Dukungan dual SIM (0 = Tidak, 1 = Ya)

5	fc	int64	Resolusi kamera depan dalam megapiksel
6	four_g	int64	Dukungan jaringan 4G (0 = Tidak, 1 = Ya)
7	int_memory	int64	Kapasitas memori internal dalam GB
8	m_dep	float64	Ketebalan bodi ponsel dalam cm
9	mobile_wt	int64	Berat ponsel dalam gram
10	n_cores	int64	Jumlah inti prosesor (core)
11	pc	int64	Resolusi kamera belakang dalam megapiksel
12	px_height	int64	Tinggi resolusi layar dalam piksel
13	px_width	int64	Lebar resolusi layar dalam piksel
14	ram	int64	Kapasitas RAM dalam MB
15	sc_h	int64	Tinggi layar dalam cm
16	sc_w	int64	Lebar layar dalam cm
17	talk_time	int64	Durasi baterai saat digunakan untuk panggilan (jam)
18	three_g	int64	Dukungan jaringan 3G (0 = Tidak, 1 = Ya)
19	touch_screen	int64	Layar sentuh (0 = Tidak, 1 = Ya)
20	wifi	int64	Dukungan WiFi (0 = Tidak, 1 = Ya)
21	price_range	int64	Variabel Target; Kategori harga ponsel (0–3)

2.3 Variabel Target dan Alasan Pemilihan

Variabel target yang digunakan adalah **price_range**, yaitu kolom yang merepresentasikan kategori harga ponsel dalam 4 kelas ordinal:

Nilai	Kategori
0	Harga Rendah (<i>Low Cost</i>)
1	Harga Menengah (<i>Medium Cost</i>)

2	Harga Tinggi (<i>High Cost</i>)
3	Harga Sangat Tinggi (<i>Very High Cost</i>)

Alasan Pemilihan Variabel Target:

Variabel `price_range` dipilih sebagai variabel target dalam *project* ini karena secara langsung merepresentasikan tujuan utama analisis, yaitu mengklasifikasikan segmen harga perangkat mobile berdasarkan spesifikasi teknisnya. Pemilihan variabel ini didasarkan pada beberapa pertimbangan berikut:

1. Variabel `price_range` memiliki label yang jelas dan terstruktur dalam empat kategori ordinal, mulai dari harga rendah hingga harga sangat tinggi sehingga cocok untuk dimodelkan sebagai permasalahan klasifikasi multikelas. Berbeda dengan regresi yang memprediksi nilai kontinu, pendekatan klasifikasi lebih sesuai di sini karena *output* yang diharapkan adalah pengelompokan harga, bukan angka harga secara spesifik.
2. Distribusi kelas pada variabel target ini terbilang sangat ideal, di mana masing-masing kelas memiliki jumlah observasi yang sama persis, yaitu sebanyak 500 data per kelas. Kondisi ini menghindari bias model terhadap kelas tertentu dan memungkinkan evaluasi kinerja model dilakukan secara lebih objektif menggunakan metrik seperti *Accuracy*, *Precision*, *Recall*, dan *F1-Score*.
3. Permasalahan yang diangkat memiliki relevansi praktis yang nyata. Dalam industri perangkat *mobile*, penentuan segmen harga merupakan salah satu keputusan bisnis yang krusial. Dengan membangun model yang mampu memprediksi kategori harga berdasarkan spesifikasi teknis seperti kapasitas RAM, resolusi kamera, dan daya baterai, hasil analisis ini berpotensi memberikan wawasan yang berguna bagi produsen maupun konsumen dalam pengambilan keputusan.

BAB III

METODOLOGI

3.1 Tools dan Library

Seluruh proses analisis dalam *project* ini dikerjakan menggunakan bahasa pemrograman Python pada platform Google Colaboratory. Library utama yang digunakan meliputi pandas dan numpy untuk manipulasi data, matplotlib dan seaborn untuk visualisasi, serta scikit-learn untuk prapemrosesan, pemodelan, dan evaluasi. Model boosting tambahan dibangun menggunakan library XGBoost (XGBClassifier).

3.2 Eksplorasi Data (*Exploratory Data Analysis*)

3.2.1 Pemeriksaan Struktur dan Kualitas Data


Tahap awal EDA dilakukan dengan memeriksa struktur dataset menggunakan fungsi `df.info()` dan `df.describe()`. Hasil pemeriksaan menunjukkan bahwa dataset terdiri dari 2.000 baris dan 21 kolom, dengan 19 kolom bertipe integer (int64) dan 2 kolom bertipe desimal (float64), yaitu `clock_speed` dan `m_dep`. Seluruh kolom terisi penuh tanpa nilai yang hilang (non-null count 2.000 pada setiap kolom).

Pemeriksaan lebih lanjut terhadap missing value menggunakan `df.isnull().sum()` dan data duplikat menggunakan `df.duplicated().sum()` memastikan bahwa dataset benar-benar bersih: tidak ditemukan satu pun missing value maupun baris duplikat. Pemeriksaan keseimbangan kelas pada variabel target `price_range` juga menunjukkan hasil yang ideal, yaitu masing-masing dari empat kelas (0, 1, 2, 3) memiliki tepat 500 observasi atau 25% dari total data, sehingga tidak diperlukan penanganan khusus untuk class imbalance.

3.2.2 Visualisasi Variabel Numerik


Empat belas variabel numerik dianalisis distribusinya menggunakan histogram dengan kurva KDE. Hasil visualisasi menunjukkan bahwa sebagian besar fitur (`battery_power`, `int_memory`, `m_dep`, `mobile_wt`, `n_cores`, `px_width`, `ram`, `sc_h`, dan `talk_time`) memiliki distribusi yang relatif merata (uniform), sementara `fc`, `pc`, `px_height`, dan `sc_w` menunjukkan distribusi

condong ke kanan (right-skewed) dengan konsentrasi nilai rendah, serta clock_speed menunjukkan pola multimodal.



Gambar 3.1 Histogram distribusi variabel numerik


Analisis boxplot digunakan untuk mendeteksi keberadaan *outlier* pada setiap variabel numerik. Hasil visualisasi mengindikasikan adanya outlier pada variabel *fc* (*front camera*) dan *px_height*, sedangkan variabel numerik lainnya relatif tidak menunjukkan *outlier* yang signifikan.



Gambar 3.2 Boxplot variabel numerik sebelum penanganan *outlier*


Scatter plot antara setiap variabel numerik dengan *price_range* digunakan untuk mengamati pola hubungan awal terhadap target. Variabel *ram* menunjukkan pemisahan kelas yang sangat jelas dan konsisten, diikuti oleh *battery_power*, *px_height*, dan *px_width* yang

menunjukkan kecenderungan positif yang lebih moderat. Variabel lain seperti clock_speed, int_memory, m_dep, mobile_wt, n_cores, sc_h, sc_w, dan talk_time tidak menunjukkan pola hubungan yang jelas terhadap target.



Gambar 3.3 Scatterplot variabel numerik terhadap price_range

Heatmap korelasi Pearson antar variabel numerik beserta target menegaskan temuan dari scatter plot. Variabel ram memiliki korelasi sangat kuat terhadap price_range dengan koefisien 0,92, jauh di atas variabel lain seperti battery_power (0,20), px_width (0,17), dan px_height (0,15). Heatmap ini juga mengungkap adanya multikolinearitas moderat antar fitur, yaitu antara fc dan pc (0,64), serta antara px_height dan px_width (0,51) dan antara sc_h dan sc_w (0,51).




Gambar 3.4 Heatmap korelasi variabel numerik dan price_range


3.2.3 Visualisasi Variabel Kategorik

Enam variabel biner (blue, dual_sim, four_g, three_g, touch_screen, wifi) dianalisis menggunakan bar chart bertingkat (stacked by price_range) dan pie chart. Hasil visualisasi menunjukkan bahwa lima dari enam variabel biner tersebut memiliki distribusi yang hampir seimbang antara kategori 0 dan 1 (sekitar 49%–52%), kecuali variabel three_g yang didominasi

oleh nilai 1 (mendukung 3G) sebesar 76,1%, sedangkan hanya 23,9% perangkat yang tidak mendukung 3G.




Gambar 3.5 Bar chart variabel kategorik terhadap price_range



Gambar 3.6 Pie chart distribusi variabel kategorik dan target price_range

Heatmap korelasi pada variabel kategorik menunjukkan bahwa three_g (0,20) dan four_g (0,15) memiliki korelasi positif moderat terhadap price_range, sementara blue, dual_sim, touch_screen, dan wifi memiliki korelasi yang sangat lemah (mendekati 0). Ditemukan pula multikolinearitas antara four_g dan three_g (0,58), yang secara intuitif wajar karena perangkat dengan dukungan 4G hampir selalu mendukung 3G.



Gambar 3.7 Heatmap korelasi variabel kategorik dan price_range

3.3 Prapemrosesan dan Rekayasa Fitur


3.3.1 Penanganan *Outlier*

Penanganan outlier dilakukan menggunakan metode *Interquartile Range* (IQR), di mana nilai yang berada di luar rentang $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$ dipangkas (*capping*) ke batas bawah atau batas atas terdekat. Pendekatan *capping* dipilih daripada penghapusan baris (*deletion*) agar tidak mengurangi jumlah observasi yang tersedia untuk pelatihan model. Hasil penerapan metode ini terhadap seluruh kolom numerik dirangkum pada Tabel 3.1.

Kolom	Jumlah <i>Outlier</i> Ditangani	Keterangan
battery_power	0	Tidak ada <i>outlier</i> signifikan
clock_speed	0	Tidak ada <i>outlier</i> signifikan

fc	18	<i>Outlier</i> di-cap ke batas atas IQR
int_memory	0	Tidak ada <i>outlier</i> signifikan
m_dep	0	Tidak ada <i>outlier</i> signifikan
mobile_wt	0	Tidak ada <i>outlier</i> signifikan
n_cores	0	Tidak ada <i>outlier</i> signifikan
pc	0	Tidak ada <i>outlier</i> signifikan
px_height	2	<i>Outlier</i> di-cap ke batas atas IQR
px_width	0	Tidak ada <i>outlier</i> signifikan
ram	0	Tidak ada <i>outlier</i> signifikan
sc_h	0	Tidak ada <i>outlier</i> signifikan
sc_w	0	Tidak ada <i>outlier</i> signifikan
talk_time	0	Tidak ada <i>outlier</i> signifikan

Secara keseluruhan, hanya 20 dari 2.000 observasi yang terdampak proses capping, yaitu 18 pada kolom fc dan 2 pada kolom px_height. Hal ini menunjukkan bahwa dataset relatif bersih dari outlier ekstrem. Boxplot setelah penanganan outlier (Gambar 3.8) memperlihatkan rentang nilai fc dan px_height yang sudah lebih terkendali dibandingkan sebelumnya.



Gambar 3.8 *Boxplot* variabel numerik setelah penanganan *outlier* (IQR capping)

3.3.2 Seleksi Fitur (*Feature Selection*)

Seleksi fitur dilakukan menggunakan SelectKBest dengan skor mutual information (*mutual_info_classif*), yang mampu menangkap hubungan non-linear antara fitur dan target sehingga lebih sesuai untuk permasalahan klasifikasi multikelas dibandingkan korelasi Pearson. Proses ini diterapkan terhadap seluruh 20 variabel fitur (14 numerik dan 6 kategorik biner) dengan parameter $k=10$, yaitu memilih 10 fitur dengan skor *mutual information* tertinggi.

Hasil seleksi fitur menghasilkan 10 fitur terpilih beserta skor mutual information masing-masing sebagaimana dirangkum pada Tabel 3.2.

Tabel 3.2 Hasil Seleksi 10 Fitur Terpilih

Fitur Terpilih	Skor <i>Mutual Information</i>
ram	0,8456
blue	0,0307
fc	0,0294
three_g	0,0279
px_height	0,0266
battery_power	0,0259
px_width	0,0235
m_dep	0,0201
sc_w	0,0162
touch_screen	0,0114

Hasil ini konsisten dengan temuan pada tahap EDA, di mana ram memiliki skor mutual information yang jauh lebih tinggi (0,8456) dibandingkan fitur lainnya, menegaskan posisinya sebagai prediktor paling dominan terhadap price_range. Kesepuluh fitur terpilih inilah yang selanjutnya digunakan sebagai input pada seluruh proses pemodelan.

3.3.3 Pembagian Data dan *Scaling*

Data dibagi menjadi data latih (*train*) dan data uji (*test*) dengan proporsi 80:20 menggunakan train_test_split, disertai parameter stratify=y untuk menjaga proporsi kelas target tetap seimbang pada kedua subset, serta random_state=42 untuk memastikan hasil pembagian dapat direproduksi. Pembagian ini menghasilkan 1.600 data latih dan 400 data uji.

Standardisasi fitur numerik dilakukan menggunakan StandardScaler. Untuk mencegah kebocoran data (data leakage), proses fit scaler hanya dilakukan pada data latih, kemudian transformasi yang dihasilkan diterapkan pada data latih dan data uji secara terpisah (fit_transform

pada train, transform saja pada test). Pendekatan ini memastikan bahwa informasi statistik dari data uji tidak ikut memengaruhi proses standarisasi.

3.4 Pemodelan (*Modeling*)

Empat skema pemodelan dibangun dan dibandingkan dalam *project* ini menggunakan 10 fitur terpilih hasil SelectKBest, yaitu:

1. *Logistic Regression* dengan solver lbfgs, max_iter=1000, random_state=42, digunakan sebagai model *baseline linear*.
2. *Random Forest* dengan n_estimators=100, max_depth=12, min_samples_split=5, min_samples_leaf=2, max_features='sqrt', random_state=42.
3. *Random Forest* (Top 6 Fitur) dimana model Random Forest dengan konfigurasi identik, namun hanya menggunakan 6 fitur dengan feature importance tertinggi (ram, battery_power, px_width, px_height, sc_w, m_dep), untuk mengevaluasi *trade-off* antara kompleksitas model dan kinerja prediktif.
4. XGBoost yang dilatih dua kali, yaitu dengan parameter default (random_state=42) dan dengan *hyperparameter* hasil *tuning* GridSearchCV.

Hyperparameter tuning dilakukan khusus pada model XGBoost menggunakan GridSearchCV dengan 5-fold cross-validation pada ruang pencarian (param_grid) sebagai berikut:

- n_estimators $\in \{100, 150, 200\}$
- max_depth $\in \{3, 5, 7\}$
- learning_rate $\in \{0,05; 0,1; 0,2\}$
- min_child_weight $\in \{1, 3, 5\}$

Didapatkan total 81 kombinasi parameter yang diuji melalui 405 proses *fitting*. Metrik *scoring* yang digunakan adalah *accuracy*.

Sebagai pembanding sederhana (*baseline*), kinerja model *Logistic Regression* pada tahap awal modeling sekaligus berfungsi sebagai acuan minimum yang harus dilampaui oleh model-model yang lebih kompleks seperti Random Forest dan XGBoost.

3.5 Metrik Evaluasi


Karena permasalahan ini merupakan klasifikasi multikelas dengan distribusi kelas yang seimbang, metrik evaluasi yang digunakan meliputi *Accuracy*, *Precision*, *Recall*, dan *F1-Score* (rata-rata *weighted*), *Confusion Matrix* untuk melihat distribusi kesalahan klasifikasi antar kelas, serta ROC-AUC dengan pendekatan *One-vs-Rest* (OvR) untuk mengukur kemampuan model dalam membedakan setiap kelas secara individual. Evaluasi dilakukan baik pada data latih maupun data uji untuk setiap model, guna mendeteksi indikasi *overfitting* melalui perbandingan (gap) antara akurasi *training* dan *testing*.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Pemodelan *Logistic Regression*

Model *Logistic Regression* dilatih menggunakan 10 fitur terpilih hasil SelectKBest yang telah distandardisasi. Hasil evaluasi pada data *training* menunjukkan *accuracy* sebesar 0,95 (95%) dengan *precision*, *recall*, dan *F1-Score* yang konsisten tinggi di seluruh kelas (berkisar 0,94–0,97). Pada data *testing*, model justru menunjukkan performa yang sedikit lebih baik, yaitu *accuracy* 0,9675 (96,75%), dengan *precision* dan *recall* di atas 0,96 untuk seluruh kelas.



Gambar 4.1 *Confusion matrix Logistic Regression data training*




Gambar 4.2 *Confusion matrix Logistic Regression data testing*


Confusion matrix pada data *testing* menunjukkan bahwa kesalahan klasifikasi yang terjadi sebagian besar berada di antara kelas yang bersebelahan (misalnya kelas 1 dengan kelas 2), yang merupakan pola wajar mengingat *price_range* bersifat ordinal. Tidak ditemukan kesalahan klasifikasi antara kelas yang berjauhan (misalnya kelas 0 dengan kelas 3), yang mengindikasikan model mampu menangkap urutan (ordinal) segmen harga dengan baik.

4.2 Hasil Pemodelan *Random Forest*

Model *Random Forest* dengan seluruh 10 fitur terpilih menunjukkan performa hampir sempurna pada data *training*, dengan *accuracy* 0,997 (99,7%). Namun, pada data *testing*, *accuracy* turun cukup signifikan menjadi 0,9175 (91,75%), menghasilkan gap sebesar 0,0794 (7,94%) antara akurasi *training* dan *testing*.



Gambar 4.3 *Confusion matrix Random Forest data training*




Gambar 4.4 *Confusion matrix Random Forest data testing*

Confusion matrix pada data *testing* menunjukkan kesalahan klasifikasi yang lebih banyak terjadi pada kelas 1 dan kelas 2 dibandingkan model *Logistic Regression*, terutama kebingungan antara kelas 1 dengan kelas 2 (9 sampel kelas 1 diklasifikasikan sebagai kelas 2, dan 8 sampel kelas 2 diklasifikasikan sebagai kelas 1). Gap performa *training* dan *testing* yang relatif besar ini mengindikasikan model *Random Forest* mengalami *overfitting* yang lebih jelas dibandingkan *Logistic Regression*.

4.2.1 *Feature Importance Random Forest*

Analisis *feature importance* dari model *Random Forest* menegaskan dominasi variabel *ram*, dengan kontribusi sekitar 0,656 (65,6%) terhadap keputusan model, jauh di atas fitur kedua tertinggi yaitu *battery_power* (0,098). Fitur *px_width* (0,073) dan *px_height* (0,067) menempati posisi ketiga dan keempat, sementara *sc_w*, *m_dep*, *fc*, *touch_screen*, *blue*, dan *three_g* memberikan kontribusi yang relatif kecil (di bawah 0,03).




Gambar 4.5 *Feature importance model Random Forest*


Temuan ini konsisten dengan hasil korelasi dan mutual information pada tahap EDA dan seleksi fitur, yang juga menunjukkan ram sebagai prediktor paling dominan. Hal ini menjawab rumusan masalah pertama *project* ini, yaitu terdapat ketimpangan kontribusi yang sangat besar antar fitur, dengan ram secara konsisten menjadi fitur paling dominan lintas seluruh metode analisis (korelasi, *mutual information*, dan *feature importance* berbasis *tree*).

4.2.2 *Random Forest* dengan Top 6 Fitur

Untuk menjawab rumusan masalah kedua mengenai sejauh mana model dapat mempertahankan akurasi dengan subset fitur yang lebih sedikit, dibangun model *Random Forest* baru menggunakan hanya 6 fitur dengan *importance* tertinggi, yaitu ram, battery_power, px_width, px_height, sc_w, dan m_dep. Hasilnya, *accuracy* pada data *testing* justru meningkat sedikit menjadi 0,93 (93%) dibandingkan model dengan 10 fitur (91,75%), meskipun pada data *training* tetap menunjukkan performa hampir sempurna (*accuracy* 0,997).



Gambar 4.6 Confusion matrix Random Forest (Top 6 Fitur) data *training*




Gambar 4.7 Confusion matrix Random Forest (Top 6 Fitur) data *testing*

Hasil ini menunjukkan bahwa pengurangan jumlah fitur dari 10 menjadi 6 tidak menurunkan kinerja model, bahkan sedikit meningkatkannya, sekaligus menghasilkan model yang lebih sederhana dan lebih cepat untuk dilatih maupun diinferensi. Gap *overfitting* (*training* dan *testing*) pada model ini adalah 0,0669 (6,69%), sedikit lebih kecil dibandingkan model *Random Forest* dengan 10 fitur (7,94%).


4.3 Hasil Pemodelan XGBoost

4.3.1 XGBoost dengan Parameter Default

Model XGBoost dengan parameter default menunjukkan performa sempurna pada data *training* (accuracy 1,00 atau 100%) dan performa sangat baik pada data testing dengan *accuracy* 0,9475 (94,75%). *Precision*, *recall*, dan *F1-Score* pada data *testing* berkisar antara 0,90 hingga 0,99 di seluruh kelas.



Gambar 4.8 Confusion matrix XGBoost (default) data *training*



Gambar 4.9 Confusion matrix XGBoost (default) data *testing*

Gap antara akurasi *training* dan *testing* pada model ini adalah 0,0525 (5,25%), lebih kecil dibandingkan *Random Forest* (7,94%), yang mengindikasikan XGBoost memiliki kemampuan generalisasi yang sedikit lebih baik dibandingkan *Random Forest* pada konfigurasi default.

4.3.2 XGBoost dengan *Hyperparameter Tuning* (GridSearchCV)

Pencarian *hyperparameter* optimal melalui GridSearchCV dengan 5-fold *cross-validation* menghasilkan kombinasi parameter terbaik berupa *learning_rate*=0,2, *max_depth*=3, *min_child_weight*=5, dan *n_estimators*=200, dengan skor *cross-validation accuracy* sebesar 0,9100 (91%). Ketika dievaluasi pada data *testing*, model XGBoost hasil tuning ini mencatatkan *accuracy* 0,9450 (94,5%), dengan *precision*, *recall*, dan *F1-Score* yang konsisten pada rentang 0,90–0,99.

Menariknya, hasil *tuning* ini secara nominal sedikit lebih rendah dibandingkan XGBoost default (94,75%), namun gap *overfitting* yang dihasilkan (0,0544 atau 5,44%) tetap berada pada level yang terkendali dan sebanding dengan model default. Hal ini menunjukkan bahwa proses *tuning* berhasil menghasilkan model yang lebih general (*less prone to overfitting*) tanpa mengorbankan akurasi secara berarti.

4.4 Perbandingan Kinerja Antar Model

Seluruh model yang telah dibangun dibandingkan kinerjanya pada data testing menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score* (*weighted average*), sebagaimana dirangkum pada Tabel 4.1.

Model	Accuracy	Precision	Recall	F1-Score
<i>Logistic Regression</i>	0,9675	0,9674	0,9675	0,9673
<i>Random Forest</i>	0,9175	0,9172	0,9175	0,9173
<i>Random Forest</i> (Top 6)	0,9300	0,9303	0,9300	0,9301
XGBoost (Default)	0,9475	0,9473	0,9475	0,9473
XGBoost (GridSearchCV)	0,9450	0,9450	0,9450	0,9448

Selain perbandingan metrik klasifikasi, dilakukan pula perbandingan ROC-AUC (*weighted, One-vs-Rest*) untuk mengukur kemampuan masing-masing model dalam membedakan antar kelas, sebagaimana dirangkum pada Tabel 4.2.

Model	ROC-AUC (<i>Weighted OvR</i>)
<i>Logistic Regression</i>	0,9986
<i>Random Forest</i>	0,9889
<i>Random Forest</i> (Top 6)	0,9930
XGBoost (Default)	0,9955
XGBoost (GridSearchCV)	0,9955

Nilai ROC-AUC seluruh model berada pada rentang yang sangat tinggi (di atas 0,98), menunjukkan bahwa kelima model sama-sama memiliki kemampuan diskriminasi antar kelas yang sangat baik. *Logistic Regression* mencatatkan ROC-AUC tertinggi (0,9986), diikuti oleh XGBoost default dan XGBoost hasil *tuning* (masing-masing 0,9955).

4.5 Analisis *Overfitting*

Untuk mengevaluasi kemampuan generalisasi setiap model secara lebih menyeluruh, dilakukan perbandingan langsung antara akurasi pada data *training* dan data *testing*, sebagaimana dirangkum pada Tabel 4.3.

Model	<i>Train Accuracy</i>	<i>Test Accuracy</i>	Gap
<i>Logistic Regression</i>	0,9544	0,9675	-0,0131
<i>Random Forest</i>	0,9969	0,9175	0,0794
<i>Random Forest</i> (Top 6)	0,9969	0,9300	0,0669
XGBoost (Default)	1,0000	0,9475	0,0525
XGBoost (GridSearchCV)	0,9994	0,9450	0,0544

Tabel di atas memperlihatkan pola yang menarik dimana *Logistic Regression* adalah satu-satunya model dengan gap negatif (-0,0131), yang berarti akurasi pada data testing justru sedikit lebih tinggi daripada data *training*. Kondisi ini menunjukkan bahwa model tidak mengalami *overfitting* sama sekali, dan justru sangat stabil dalam melakukan generalisasi pada data baru.

Sebaliknya, model-model berbasis pohon keputusan (*tree-based*) seperti *Random Forest* dan XGBoost cenderung mencapai akurasi training yang sangat tinggi hingga mendekati sempurna (0,997–1,000), namun mengalami penurunan performa yang cukup terasa pada data *testing*. *Random Forest* dengan seluruh fitur menunjukkan gap terbesar (0,0794), sementara XGBoost default memiliki gap paling kecil di antara model *tree-based* (0,0525). Hal ini sejalan dengan karakteristik umum algoritma *ensemble* berbasis pohon yang cenderung lebih fleksibel dalam menangkap pola data *training*, sehingga lebih rentan terhadap *overfitting* apabila tidak diatur dengan regularisasi yang memadai.

4.6 Model Terbaik

Berdasarkan keseluruhan hasil evaluasi pada Tabel 4.1, Tabel 4.2, dan Tabel 4.3, model *Logistic Regression* dipilih sebagai model terbaik dalam *project* ini, dengan pertimbangan sebagai berikut:

1. *Logistic Regression* mencatatkan *accuracy testing* tertinggi (96,75%) di antara seluruh model yang diuji, termasuk dibandingkan dengan model yang lebih kompleks seperti XGBoost hasil *tuning*.
2. Model ini tidak menunjukkan indikasi *overfitting* dengan gap antara akurasi *training* dan *testing* bernilai negatif (-0,0131), yang berarti kemampuan generalisasinya pada data baru sangat baik dan stabil.
3. *Logistic Regression* juga mencatatkan ROC-AUC tertinggi (0,9986), menunjukkan kemampuan diskriminasi antar kelas yang paling unggul.
4. Sebagai model linear, *Logistic Regression* jauh lebih sederhana dan mudah diinterpretasikan dibandingkan *Random Forest* maupun XGBoost, sehingga lebih sesuai dengan prinsip parsimoni dalam pemilihan model *machine learning*.

Model XGBoost, baik versi default maupun hasil tuning GridSearchCV, tetap menjadi kandidat yang sangat kompetitif dengan akurasi *testing* di atas 94% dan gap *overfitting* yang masih terkendali (di bawah 6%), sehingga dapat menjadi alternatif yang baik apabila pola hubungan antar fitur diasumsikan lebih kompleks dan non-linear pada konteks data yang berbeda. Sebaliknya, *Random Forest* dengan seluruh fitur menunjukkan kinerja yang paling rendah dan gap *overfitting* paling besar di antara seluruh model yang diuji, meskipun penggunaan subset 6 fitur teratas (*Random Forest* Top 6) berhasil memperbaiki kinerjanya secara moderat.

4.7 Pembahasan Terhadap Rumusan Masalah

Hasil analisis pada bab ini dapat digunakan untuk menjawab ketiga rumusan masalah yang diajukan pada Bab I:

1. Ketimpangan kontribusi fitur

Terdapat ketimpangan kontribusi yang sangat besar antar fitur teknis. Variabel *ram* secara konsisten menjadi fitur paling dominan lintas seluruh metode analisis yang digunakan, baik korelasi Pearson (0,92), *mutual information* (0,8456), maupun *feature importance Random Forest* (0,656), sementara mayoritas fitur lain memberikan kontribusi yang sangat kecil.

2. Kinerja model dengan subset fitur

Model *machine learning* mampu mempertahankan, bahkan sedikit meningkatkan, akurasi klasifikasi ketika dibangun menggunakan subset fitur terpilih. *Random Forest* dengan 6 fitur teratas mencapai *accuracy testing* 93%, lebih tinggi dibandingkan *Random Forest* dengan 10 fitur (91,75%), menunjukkan bahwa fitur dengan kontribusi rendah dapat dihilangkan tanpa mengorbankan, dan bahkan dapat memperbaiki, kinerja model.

3. Algoritma paling optimal

Diantara seluruh algoritma yang diuji (*Logistic Regression*, *Random Forest*, dan XGBoost), *Logistic Regression* terbukti paling optimal untuk menangani pola klasifikasi multikelas pada dataset ini, dengan akurasi testing tertinggi (96,75%), ROC-AUC tertinggi (0,9986), dan tanpa indikasi *overfitting*.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan seluruh proses analisis yang telah dilakukan, mulai dari eksplorasi data, prapemrosesan, seleksi fitur, pemodelan, hingga evaluasi, dapat disimpulkan beberapa hal sebagai berikut:

1. *Dataset Mobile Price Classification* yang digunakan dalam *project* ini bersih dari *missing value* dan duplikat, serta memiliki distribusi kelas target yang seimbang sempurna (500 observasi per kelas), sehingga sangat ideal untuk dijadikan studi kasus klasifikasi multikelas.
2. Variabel *ram* merupakan fitur yang paling dominan dan konsisten berpengaruh terhadap penentuan segmen harga perangkat mobile, terbukti dari korelasi, skor *mutual information*, maupun *feature importance* yang jauh melampaui fitur-fitur lainnya.
3. Model *machine learning* mampu mempertahankan, bahkan meningkatkan, kinerja klasifikasi ketika dibangun hanya dengan subset fitur terpilih (top 6) dibandingkan menggunakan seluruh fitur, menegaskan bahwa sebagian besar fitur teknis dalam dataset ini bersifat redundan terhadap tugas klasifikasi *price_range*.
4. Dari lima skema pemodelan yang diuji, *Logistic Regression* terbukti sebagai model paling optimal dengan *accuracy testing* 96,75%, ROC-AUC 0,9986, dan tanpa indikasi *overfitting*, mengungguli model yang lebih kompleks seperti *Random Forest* dan *XGBoost*.
5. Model berbasis pohon keputusan (*Random Forest* dan *XGBoost*) menunjukkan kecenderungan *overfitting* yang lebih besar dibandingkan model linear pada dataset ini, meskipun *XGBoost* menunjukkan gap *overfitting* yang lebih terkendali dibandingkan *Random Forest*.

5.2 Keterbatasan Penelitian

Keterbatasan dari penelitian yang telah kami lakukan adalah:

1. *Project* ini hanya menggunakan satu sumber dataset (Kaggle) tanpa validasi terhadap data spesifikasi perangkat *mobile* dari sumber atau periode waktu yang berbeda, sehingga generalisasi hasil ke kondisi pasar saat ini perlu diuji lebih lanjut.
2. Seleksi fitur yang digunakan terbatas pada pendekatan filter *method* (SelectKBest dengan *mutual information*) dan *feature importance* berbasis *tree*, tanpa membandingkan dengan

metode *wrapper* seperti *Recursive Feature Elimination* (RFE) yang berpotensi menghasilkan subset fitur yang berbeda.

3. *Hyperparameter tuning* hanya diterapkan secara menyeluruh pada model XGBoost, sehingga belum dapat dipastikan apakah model *Random Forest* dapat mencapai kinerja yang lebih baik apabila parameter-parameternya juga dioptimasi menggunakan GridSearchCV atau RandomizedSearchCV.

5.3 Saran

1. Bagi penelitian selanjutnya, disarankan untuk melakukan *hyperparameter tuning* yang lebih menyeluruh pada seluruh model, termasuk *Random Forest* dan *Logistic Regression*, untuk memastikan perbandingan antar model dilakukan pada kondisi yang optimal bagi masing-masing algoritma.
2. Penambahan data dari sumber atau periode lain dapat dilakukan untuk menguji konsistensi dominasi fitur ram terhadap segmen harga perangkat *mobile* pada konteks pasar yang lebih baru.
3. Eksplorasi metode seleksi fitur lain, seperti *Recursive Feature Elimination* (RFE) atau metode berbasis SHAP value, dapat dilakukan untuk memperkaya analisis interpretasi model di luar *feature importance* bawaan *Random Forest*.
4. Bagi produsen perangkat *mobile*, hasil *project* ini dapat dijadikan acuan awal bahwa kapasitas RAM merupakan faktor teknis paling krusial dalam *positioning* harga produk, sehingga keputusan spesifikasi RAM perlu mendapat perhatian utama dalam strategi penetapan segmen harga.

LAMPIRAN

Lampiran 1: Link AI

<https://chatgpt.com/c/6a3acfd0-565c-83ec-90e8-0c441029d9e1>

<https://claude.ai/chat/c41e66f8-fd8f-484e-ae10-670c7d7f3ec2>

<https://claude.ai/chat/bf452cbc-6353-4392-ba2f-970271920410>

Lampiran 2: Link Github

https://github.com/wahyuramadhan50777-prog/Project_Machine-Learning_Kelompok-C